Análisis de datos metagenómicos con QIIME2e

El objetivo de esta actividad es familiarizarse con el software *Qiime2* para realizar análisis de datos metagenómicos en una comunidad microbiana e interpretar sus resultados. Para ello, se generan archivos compatibles con el software (.qza) y para su visualización con *Qimme2 View* (.qzv). A continuación, se describen los pasos para realizar esta tarea.

Paso 1: Obtención de datos y preparación del entorno.

En el primer paso, se prepara el entorno de trabajo creando un directorio de trabajo llamado *qiime2-atacama* para facilitar el manejo de los archivos. A continuación, se descargan los archivos necesarios: metadatos de las muestras (***sample-metadata.tsv***), y las secuencias crudas con los códigos de barras asociados (***forward.fastq, reverse.fastq y barcodes.fastq***).

Paso 2. Crear el artefacto de Qiime2 con las secuencias.

Se genera un archivo con una estructura estándar que almacena los datos junto con los metadatos asociados de forma reproducible y compatible para ser analizados por otras herramientas de Qiime2. El archivo es ***emp-paired-end-sequences.qza***.

Paso 3. Demultiplexar las *reads.*

Se separan las secuencias de ADN o ARN por cada muestra usando los códigos de barras (*barcodes*) definidos en la columna *barcode-sequence* de los metadatos, estableciendo identificadores únicos para las secuencias en cada una de las muestras. En este paso se generan los archivos ***demux-full.qza*** *y* ***demux-details.qza***.

Paso 4. Crear una submuestra.

Para reducir tiempos de computación, se selecciona un subconjunto con el 30% de las lecturas y se genera los archivos ***demux-subsample.qza*** y ***demux-subsample.qzv***.

Paso 5. Filtrar de muestras con baja profundidad.

Se eliminan las muestras con menos de 100 reads del archivo generado en el paso anterior, ya que aportan poca información y pueden introducir sesgos en los análisis posteriores. El resultado es un conjunto de datos más robusto, el cual se va a establecer exportando los datos al archivo ***demux.qza***.

Paso 6. Revisar la calidad y realizar *denoising.*

Se evalúa la calidad de las secuencias y se aplica el algoritmo *DADA2*, que mediante el proceso de *denoising*, se va a eliminar ruido y a corregir errores. Esto asegura el uso de secuencias de alta calidad y una representación más precisa de la comunidad. Se genera una tabla de abundancia de OTUs/ASVs o features (***table.qza***), secuencias representativas (***rep-seps.qza***) y estadísticas de la eliminación del ruido (***denoising-stats.qza***), además de los resúmenes de los resultados con la información necesaria y las secuencias representativas (***table.qzv, rep-seqs.qzv***) con la que se va trabajar en los análisis de composición taxonómica de esta comunidad microbiana.

Paso 7. Generar un árbol para el análisis de diversidad filogenética

A partir de las secuencias representativas, se realiza una alineación de las secuencias con *MAFFT* y se genera un árbol filogenético mediante *FastTree*, que luego será enraizado. El árbol obtenido, se exporta en formato *Newick* (***tree.nwk***), y va a ser clave para cuantificar la diversidad filogenética, interpretar la composición y estructura de la comunidad microbiana, su relación evolutiva, realizar comparaciones funcionales, explicar patrones filogenéticos, facilitar comparaciones estadísticas, y analizar la diversidad alfa y beta de la comunidad.

Paso 8. Cálculo de diversidad alfa.

Para el cálculo de la diversidad alfa y beta, se utiliza la técnica de rarefacción para normalizar las muestras según la profundidad de secuenciación que permite un equilibrio entre la conservación de suficientes muestras para obtener resultados robustos y la exclusión de muestras con baja cobertura que pueden introducir ruido. La diversidad alfa describe la diversidad dentro de una comunidad, pudiéndose evaluar su estructura y complejidad a partir de: las *características observadas*, que reflejan la riqueza de especies; el índice de *Shannon*, que integra riqueza y equidad; la diversidad filogenética de *Faith*, que considera las relaciones evolutivas entre los organismos; y la igualdad de *Pielou*, que mide la equidad en la distribución de las abundancias entre las especies presentes.

PREGUNTAS

¿Qué profundidad de muestreo debemos seleccionar? Se debe seleccionar la profundidad que permita la representación del mayor número de muestras y maximizar el poder estadístico del análisis. **Observa cuántas secuencias tiene cada**

muestra visualizando la tabla *table.qzv* y selecciona la profundidad de muestreo. ¿Cuáles son los valores menores y mayores de secuencias en una muestra? El valor menor es de 14 y el mayor es de 2118. **¿Cuál es la mediana?** La mediana es 1190,5. **¿Y el promedio?** El promedio es 1189,16. **¿Qué valor permitirá que mantengamos la mayor cantidad de muestras posibles?** Se escoge el valor 465 para mantener la mayor cantidad de muestras posibles, teniendo en cuenta la conservación de dos muestras del grupo BAQ2838 para posteriores análisis estadísticos y no perder la información de esta muestra. **En base a este número se realiza el paso de rarefacción de muestras. ¿Qué variable categórica de los metadatos está asociada con más fuerza con las diferencias en riqueza de la comunidad?** Para responder esta pregunta, se utiliza el archivo *observed_features_group_significance.qzv* que corresponde a la diversidad observada para poder distinguir la variable que más afecta a la riqueza de cada grupo dentro de la comunidad. La variable que muestra mayor fuerza en las diferencias de la comunidad es "*Vegetation*" (*Kruskal–Wallis; H = 18,31; p = 0.000018*). **¿Y con igualdad?** Aquí se utiliza el archivo que corresponde a la Igualdad de *Pielou* (*evenness_vector.qza-group-significance.qzv*) para distinguir la variable con más fuerza que mide la uniformidad en la distribución de la comunidad. La variable con más fuerza es "*transect-name*" (*Kruskal–Wallis; H = 18,31; p= 0.0018*).

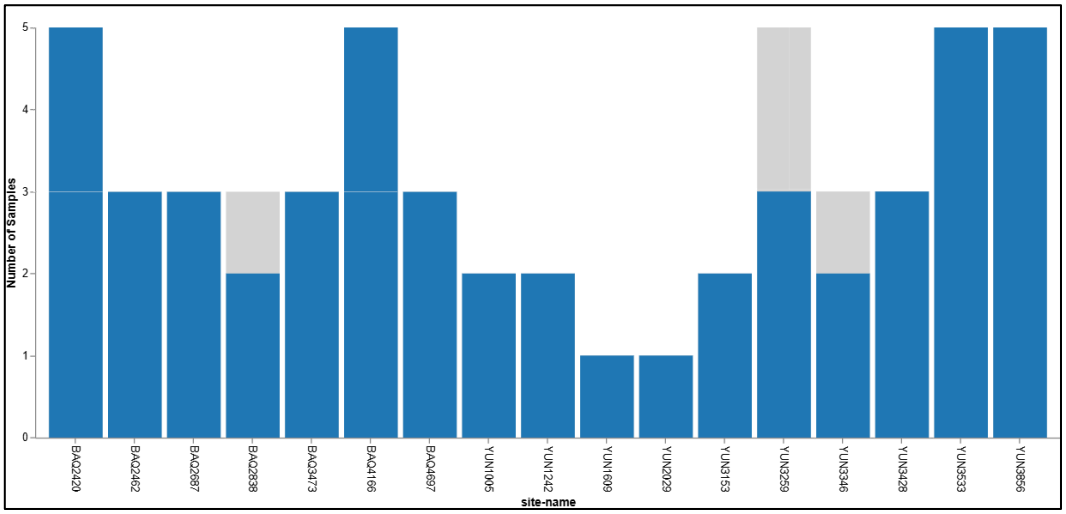


Gráfico 1. Cobertura de muestras que se mantienen a partir de una profundidad de 465.

Paso 9. Análisis taxonómico.

Para el análisis taxonómico, se asignan identidades taxonómicas (como género, familia, etc.) a las secuencias representativas de lo OTU (*req-seqs.qzv*) mediante un clasificador entrenado *nb* (*Naïve Bayes*) de una base de datos (*greengenes*),

enfocándolo en las regiones V4-V5 del gen 16S rRNA. Se va a generar un archivo de clasificación llamado ***taxonomy.qzv*** para observar un resumen de las identidades asignadas y un gráfico de abundancia ***taxa-bar-plots.qzv***.

PREGUNTA

¿Qué pasa si evaluamos algunas de las secuencias con BLAST? ¿Son las clasificaciones taxonómicas diferentes a las de QIIME2? ¿En qué nivel taxonómico surgen las diferencias?

Para responder a estas preguntas, cogemos tres secuencias diferentes con un alto porcentaje de identidad que estén asociados a nivel género en el archivo *rep-seqs.qzv*, copiamos sus secuencias nucleotídicas del archivo *taxonomy.qzv* y se busca la clasificación taxonómica en *Nucleotide BLAST*. Posteriormente, se evalúan las diferencias de nivel taxonómico obtenidos en *BLAST* con el del archivo *taxa-bar-plots.qzv* obtenido en *Qiime2*.

Se escogen las secuencias con IDs: 99fa718995b3129c258bd12bdabb4bec, 04a75f1199d1bc6b58d19dd8aeb24520, 6fb34e14dde4d7b6ccd5eae63350d4a8. En el primer caso, *Qimme2* y *BLAST* coinciden en el género (*Rubrobacter)*, mientras que los otros difieren en el género, pero coinciden en la familia (*Enhydrobacter* y *Planctomyces* de las familias *Moraxellaceae* y *Planctomycetaceae* respectivamente en *Qiime2*; *Faucicola* y *Rubinisphaera* de las familias *Moraxellaceae* y *Planctomycetaceae* en *BLAST*. A partir de las secuencias de estos tres organismos, se observa que en ocasiones puede coincidir o diferir la clasificación taxonómica entre *Qiime2* y *BLAST*. Cuando surgen diferencias lo hacen a nivel de género, pero coinciden a nivel familia.

Estas diferencias en la asignación taxonómica, pueden deberse al uso de diversos enfoques, metodologías, bases de datos y criterios de confianza. *BLAST* se basa en el alineamiento directo de secuencias para asignar la clasificación según las coincidencias en su base de datos, por lo que su clasificación puede ser más específica a nivel de especie, incluso si la evidencia no es del todo concluyente, pudiendo tener mayor sensibilidad y una posible sobreclasificación. En cambio, *Qimme2* mediante la base de datos de *Greengenes*, que utiliza métodos estadísticos y niveles de confianza a partir de la optimización para secuencias cortas de amplicones para asignar la

taxonomía, priorizando la robustez de la clasificación, aunque esta sea más conservadora.

Paso 10. Análisis diferencial de abundancia microbiana.

Para el análisis diferencial de abundancia microbiana, se utiliza el método estadístico *ANCOM*, diseñado para identificar taxones que presentan una abundancia diferencial significativa entre grupos de estudio, ya que compara proporciones relativas de las características en vez de valores absolutos, y es fundamental para identificar elementos clave que puedan ser responsables de estas diferencias observadas.

Para realizar este análisis, se va a utilizar la taxonomía a nivel de género (Nivel 6) para que se más detallado y con la variable *vegetation*, que es la que muestra mayor fuerza en la diferenciación de la riqueza dentro de las comunidades. Con esto, se genera el archivo ***l6-vegetation.qzv*** para su visualización y análisis.

PREGUNTA

¿Qué géneros presentan diferencias significativas en abundancia entre grupos de muestras? Las diferencias significativas a nivel de género solo están *Ralstonia* de la familia *Oxalobacteraceae* y *DA101* de la familia *Chthoniobacteraceae.* También salen otros con diferencias significativas, pero a nivel de familia, como *Nitriliruptoraceae*; o a nivel de orden, como *Chromatiales.*

El género *Ralstonia* y la familia *Nitriliruptoraceae* salen con diferencias significativas positivas respecto a la presencia de vegetación, lo que supone un aumento en su abundancia. Esto puede ser coherente, ya que las especies del género *Ralstonia* son patógenos de las plantas, y la familia *Nitriliruptoraceae* se caracteriza por ser bacterias con capacidad de degradar compuestos nitrogenados complejos que pueden estar asociados a su liberación por las raíces de las plantas.

Sin embargo, el género *DA101* y el orden *Chromatiales* disminuyen su abundancia con la presencia de vegetación. Las especies del género *DA101* pueden verse desplazadas por otras bacterias con la presencia de vegetación debido a que son especialistas en vivir en condiciones de pocos nutrientes, y los del orden *Chromatiales* son bacterias púrpuras del azufre donde la mayoría son fotótrofas y la presencia de vegetación les impide este recurso necesario para su supervivencia.

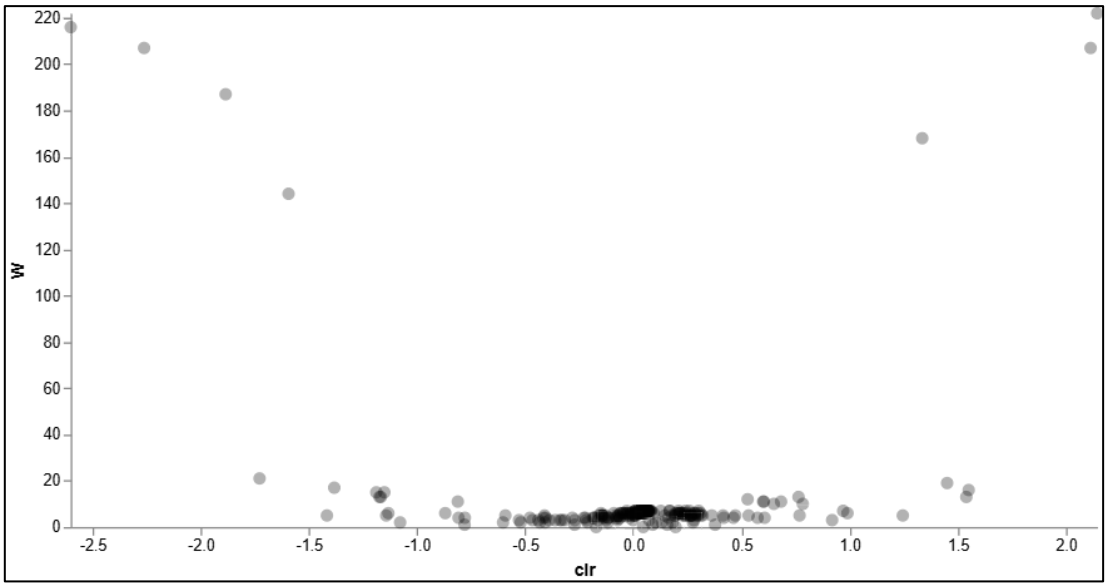


Gráfico 2. VolcanoPlot del análisis diferencial de abundancia microbiana mediante el método ANCOM.

ANEXO

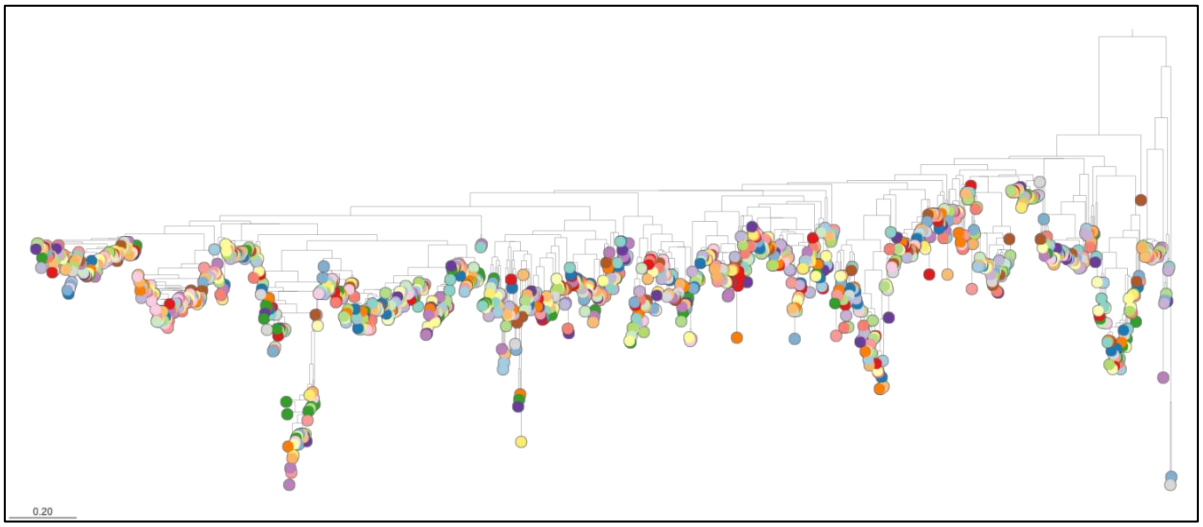


Gráfico 3. Árbol de diversidad filogenética (archivo tree.nwk)

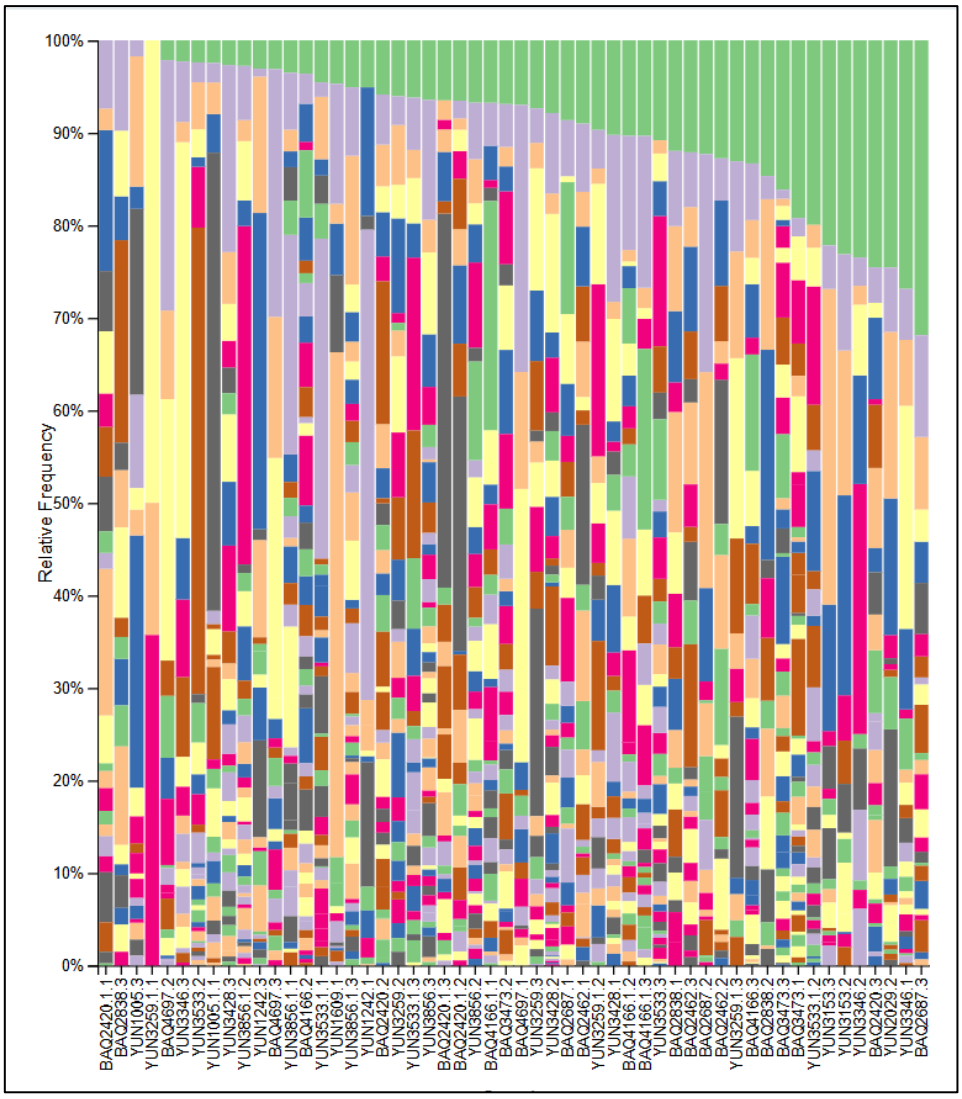


Gráfico 4. Abundancia taxonómica por muestra (archivo taxa-bar-plots.qzv)